

script.py — ¿Qué hace este código?

Resumen en lenguaje simple del pipeline completo de análisis estadístico

El archivo **script.py** es un programa en Python que descarga datos del gobierno peruano, los procesa, aplica técnicas estadísticas avanzadas, y genera automáticamente las tablas y figuras de un paper académico. Todo en un solo archivo que cualquiera puede ejecutar. A continuación se explica cada parte.

1. ¿Cuál es el objetivo general?

El script investiga si recibir **Pensión 65** — el programa del Estado que paga S/250 cada dos meses a adultos mayores en extrema pobreza — hace que esas personas adopten **billeteras digitales** (Yape, Plin, Cuenta DNI). Para eso usa datos de la Encuesta ENAHO 2024 del INEI y aplica un método estadístico llamado *Regresión Discontinua* que aprovecha el corte de edad en 65 años como experimento natural.

2. Las 5 fases del pipeline

Fase	Nombre	¿Qué hace?	Output principal
0	Descarga	Baja automáticamente 6 archivos de datos del INEI (~511 MB).	6 archivos CSV de datos: <code>enafo_2024_01.csv</code> a <code>enafo_2024_06.csv</code> .
1	Preprocesamiento	Une los 6 módulos en una sola tabla por persona (117,721 personas) y crea la variable de billetera digital.	<code>enafo_2024_uned.csv</code> (117 MB).
2	Limpieza RDD	Centra la variable de edad en el corte de 65 años. Crea dos muestras: <code>df_full</code> (todos) y <code>df_main</code> (solo pobres extremos).	<code>enafo_rdd_full.csv</code> y <code>enafo_rdd_main.csv</code> .
3	Estimación principal	Corre el RDD principal (4 especificaciones) + BLOQUE F (RDD2 <code>main</code> como variable de corte). Calcula el efecto de la pensión.	<code>rdd2_results.csv</code> .
4	Robustez	Verifica que el resultado sea robusto: cambia el ancho de ventana de estimación del corte (donut), prueba otros métodos.	<code>robustness_results.csv</code> .
5	Tablas y figuras	Genera automáticamente todas las tablas en formato LaTeX y las figuras en PNG/PDF listas para el paper.	8 tablas en LaTeX y 4 figuras .png/.pdf.

3. Variables principales que construye el script

Variable	¿Qué mide?	Fuente ENAHO
TIENE_BILLETERA	1 si tiene O usa billetera digital (Yape, Plin, Cuenta DNI)	Módulo 05 P558E1 y P558H
USA_BILLETERA	1 si usó billetera como medio de pago en alguna compra	Módulo 05 P558H
running_centere d	Edad de la persona menos 65 (cero = exactamente en el corte)	Módulo 02 P208A
POBREZA	Clasificación SISFOH: 1=extrema pobreza, 2=no extrema, 3=no pobre	Sumaria
SISFOH_PROXY	Índice construido con PCA sobre 8 variables del hogar. Más alto = más pobre.	Módulos 01, 18, Sumaria
AREA	1=urbano, 2=rural (derivado de DOMINIO)	Módulo 01 DOMINIO
HACINAMIENTO	Personas del hogar dividido entre número de cuartos	Módulos 01+02

4. Los dos diseños estadísticos (RDD1 y RDD2)

RDD1 — Corte de edad en 65 años (diseño principal)

Compara personas que están justo antes de cumplir 65 años con las que acaban de cumplirlos, **dentro de la muestra de pobres extremos**. La idea es que el único cambio relevante al cruzar esa edad es volverse elegible para Pensión 65. Si hay un salto en el uso de billeteras justo en los 65, eso se atribuye al programa.

Muestra	Solo POBREZA=1 (N=6,717)
Variable de corte (running variable)	Edad centrada en 65 años
Ventana óptima (bandwidth)	±13.95 años
N efectivo dentro de ventana	1,144 personas
Resultado principal	+2.7 pp (SE=2.2 pp) — positivo, no significativo
Prueba de aleatoriedad (p-value)	0.60 — no se rechaza la hipótesis nula
Problema principal	Solo el 5% de personas cerca del corte son elegibles

RDD2 — Índice de bienestar SISFOH como corte (BLOQUE F)

En lugar de usar la edad como variable de corte, construye un **índice de pobreza** con técnicas de reducción de dimensiones (PCA) a partir de características del hogar (paredes, piso, agua, smartphone, refrigerador, TV, ingreso, hacinamiento). El corte se define donde el índice separa a los clasificados como pobres extremos de los que no lo son. Diseño basado en Bando, Galiani y Gertler (2020).

Muestra	Todos los adultos ≥65 años (N=14,088)
Variable de corte	Índice PCA de bienestar (SISFOH_PROXY)
Varianza explicada por PC1	32.2%
Ventana óptima (bandwidth)	0.765 unidades del índice
N efectivo dentro de ventana	3,201 personas (~2.8× más que RDD1)
Resultado principal	+0.4 pp (SE=1.5 pp) — prácticamente cero
Balance de covariables	Todos balanceados (CIs incluyen cero) ✓
Ventaja vs. RDD1	Más poder estadístico y mejor balance de covariables

5. Pruebas de robustez que corre el script

- **Sensibilidad al bandwidth:** Repite el análisis con ventanas de ±7 años y ±28 años. El resultado positivo se mantiene en todos los casos.
- **Donut hole:** Excluye a las personas con exactamente 65, 64 o 63 años para asegurarse de que el resultado no depende de quienes están justo en el corte.
- **Orden del polinomio:** Prueba ajuste cuadrático en vez de lineal. El resultado es muy similar.
- **Cortes placebo:** Repite el análisis en edades donde NO debería haber efecto (ej. 46 años, 10 años antes del corte real). Si aparece un 'efecto' ahí, el diseño estaría capturando algo diferente al programa.
- **Permutaciones aleatorias (500):** Asigna el corte al azar 500 veces y compara con el efecto real. El p-value resultante es 0.60 (no significativo).
- **Balance de covariables:** Verifica que variables como internet o smartphone no cambien de golpe en los 65 años. Si cambian, algo más está pasando. Hallazgo: internet sí cambia en el RDD1 (limitación del diseño).

- **Corrección por múltiples pruebas (BH):** Ajusta los p-values para tener en cuenta que se están probando muchas hipótesis a la vez.

6. Archivos que genera el script

Archivo	¿Para qué sirve?
main_results.csv	Resultados de todos los RDD principales (9 filas)
rdd2_results.csv	Resultados del BLOQUE F (RDD2 con índice SISFOH)
robustness_results.csv	20 pruebas de robustez con sus estadísticos
dilution_calc.json	Cálculo de dilución ITT→LATE (frac_ep=5%, $\tau_{LATE}=0.719$)
table_2_main_results.tex	Tabla LaTeX: resultados RDD1 (EP baseline + covariables)
table_2b_dpto_fe.tex	Tabla LaTeX: efectos fijos por departamento
table_3_heterogeneity.tex	Tabla LaTeX: heterogeneidad urbano/rural
table_4_rdd2_sisfoh.tex	Tabla LaTeX: resultados RDD2 (BLOQUE F)
figure_1_rdplot.png	Gráfico RDD1: adopción por edad (dispersión binada)
figure_rdd2_rdplot.png	Gráfico RDD2: adopción por índice SISFOH
figure_rdd2_density.png	Histograma de densidad del índice SISFOH en el corte

RESUMEN EN UNA ORACIÓN El script descarga datos del INEI, construye indicadores de billetera digital y pobreza, aplica dos diseños de regresión discontinua (uno por edad y otro por índice de bienestar), corre 7 pruebas de robustez, y genera todas las tablas y figuras del paper académico de forma automática.