

Explicación del Código

Pipeline de Análisis RDD — Adopción de Billetera Digital (Pensión 65)

script.py · scripts/script_completo/

1. Descripción general

El archivo **script.py** implementa un **pipeline econométrico completo de extremo a extremo** para estimar el efecto causal de la afiliación a Pensión 65 sobre la adopción de billeteras digitales en Perú, utilizando un diseño de **Regresión Discontinua (RDD)** basado en el umbral de elegibilidad de 65 años.

El script está diseñado para ser **portable y autosuficiente**: cualquier persona que clone el repositorio puede ejecutarlo con un solo comando (`python scripts/script_completo/script.py`) sin necesidad de preparar datos manualmente. Descarga los microdatos directamente desde el INEI, los procesa y produce todos los outputs del paper (tablas LaTeX y figuras).

2. Estructura del pipeline (6 fases)

El pipeline se organiza en seis fases secuenciales, cada una encapsulada en su propia función:

Fase	Nombre	Función principal	Output clave
0	Descarga INEI	phase_0_download_from_inei()	6 CSVs en data/clean/_raw_extracted/
1	Preprocesamiento	phase_1_preprocess()	enaho_2024_clean.csv
2	Limpieza RDD	phase_2_clean()	clean_data.csv
3	Estimación principal	phase_3_main()	main_results.csv
4	Robustez	phase_4_robustness()	robustness_results.csv
5	Tablas y figuras	phase_5_output()	4 tablas .tex + 3 figuras .png/.pdf

3. Configuración global y rutas

Al inicio del script se definen todas las **rutas de forma relativa a la ubicación del propio archivo**, lo que garantiza portabilidad entre sistemas operativos:

- REPO_ROOT**: raíz del repositorio (dos niveles arriba de script.py).

- **DATA_DIR:** data/clean/ — almacena todos los CSV intermedios y finales.
- **RAW_EXTRACTED_DIR:** data/clean/_raw_extracted/ — CSVs crudos descargados de INEI.
- **TABLES_DIR / FIGURES_DIR:** paper/tables/ y paper/figures/ — outputs del paper.
- **RANDOM_SEED = 42:** semilla para reproducibilidad en permutaciones y simulaciones.

4. Gestión automática de dependencias

La función `install_dependencies()` y el auxiliar `ensure_package()` verifican e instalan automáticamente los paquetes necesarios mediante `pip` antes de importarlos:

- **Obligatorias** (abortan si no se pueden instalar): `pandas`, `numpy`, `matplotlib`, `statsmodels`.
- **Opcionales con fallback:** `rdrobust`, `rddensity`, `linearmodels`. Si `rdrobust` no está disponible, el estimador RDD cae automáticamente a una regresión WLS local con pesos triangulares via `statsmodels`.

5. Fase 0 — Descarga de microdatos ENAHO 2024

La función `phase_0_download_from_inei()` descarga los **6 módulos de la Encuesta ENAHO 2024** (código 966) directamente desde el servidor del INEI sin depender de archivos locales preexistentes. El proceso es:

- Construye la URL de cada módulo siguiendo el patrón: `https://proyectos.inei.gob.pe/iinei/srienaho/descarga/CSV/966-ModuloXX.zip`.
- Descarga el ZIP en memoria (sin guardarlo en disco).
- Extrae únicamente el CSV objetivo dentro del ZIP y lo escribe en `_raw_extracted/`.
- Los 6 módulos descargados suman aproximadamente **511 MB** de CSVs.

Los seis módulos descargados son:

- **Módulo 01** (Vivienda) — `Enaho01-2024-100.csv`: variables de vivienda e internet.
- **Módulo 02** (Miembros del hogar) — `Enaho01-2024-200.csv`: demografía, edad, sexo.
- **Módulo 03** (Educación) — `Enaho01A-2024-300.csv`: nivel educativo.
- **Módulo 05** (Empleo + Billetera) — `Enaho01a-2024-500.csv`: variables de outcome principal.
- **Módulo 18** (Equipamiento) — `Enaho01-2024-612.csv`: tenencia de smartphone.
- **Sumaria** — `Sumaria-2024.csv`: ingreso y gasto per cápita del hogar.

6. Fase 1 — Preprocesamiento ENAHO 2024

La función `phase_1_preprocess()` fusiona los 6 módulos a nivel de **persona** y construye las variables analíticas:

- **Variables de billetera digital** (del módulo 05): `TIENE_BILLETERA` (ítem `P558E1_9` = 9) y `USA_BILLETERA` (cualquier `P558H*_7` = 7). También construye versiones alternativas con códigos 6 y 10 para robustez.
- **Variables de formalidad laboral**: `BANCO_PREVIO`, `FORMAL`, `OCUPADO`.
- **Demografía** (módulo 02): género, edad (`EDAD`), factor de expansión.
- **Educación** (módulo 03): nivel educativo máximo.
- **Smartphone** (módulo 18 en formato long → wide): indicador de tenencia.
- **Internet en hogar** (módulo 01): variable binaria.
- **Ingreso per cápita** (sumaria): `INGHOG2D` / `MIEPERHO`.

El merge final es por llaves `CONGLOME`, `VIVIENDA`, `HOGAR`, `CODPERSONA` a nivel persona, y por `CONGLOME`, `VIVIENDA`, `HOGAR` a nivel hogar. El output es `enaho_2024_clean.csv`.

7. Fase 2 — Limpieza y construcción de la muestra RDD

La función `phase_2_clean()` prepara el dataset para la estimación RDD:

- Elimina observaciones con `EDAD` missing.
- **Centra la variable de corrida**: `running_centered` = `EDAD` - 65. Valores negativos corresponden a personas menores de 65 (control); positivos a mayores (tratados).
- Crea la variable de **tratamiento**: `treat` = 1 si `running_centered` ≥ 0.
- Reporta estadísticas de missingness, correlaciones y medias por grupo.

El output es `clean_data.csv`, que es el input de todas las fases siguientes.

8. Fase 3 — Estimación RDD principal

La función `phase_3_main()` estima el efecto causal de cruzar el umbral de 65 años sobre la adopción de billetera digital. El flujo de estimación está implementado en la función `run_rdd()` con doble fallback:

- **Estimador primario** — `rdrobust` (Calonico, Cattaneo & Titiunik): regresión local con kernel triangular, ancho de banda MSE-óptimo, errores estándar robustos bias-corrected clusterizados por departamento.
- **Estimador de respaldo** — WLS local vía `statsmodels` con pesos triangulares y errores HC2, si `rdrobust` falla.

Se estiman **tres especificaciones** para cada outcome:

- **baseline**: sin covariables.
- **with_covariates**: con internet + smartphone.
- **extended_covariates**: con internet, smartphone, pobreza, ingreso_pc, educación.

Adicionalmente se calculan tamaños de efecto (Cohen's d, % de cambio respecto a la media) y análisis de **heterogeneidad por subgrupos** (pobreza, acceso a internet, smartphone).

9. Fase 4 — Pruebas de robustez

La función `phase_4_robustness()` implementa una batería exhaustiva de verificaciones que son estándar en la literatura RDD:

#	Prueba	Descripción
1	McCrary / rddensity	Detecta manipulación en la variable de corrida. Un p-valor pequeño sugeriría selección en torno al umbral.
2	Outcomes placebo	Estima el RDD usando covariables pre-tratamiento (internet, smartphone) como outcome. No debe haber efectos.
3	Sensibilidad al BW	Repite la estimación con $h \times 0.5$ (medio BW), $h \times 1.0$ (óptimo) y $h \times 2.0$ (doble BW).
4	Donut-hole	Excluye observaciones con $ \text{running_centered} \leq 0.5 / 1.0 / 2.0$ años para descartar manipulación local.
4b	Heterogeneidad SISFOH	Separa la muestra por condición de pobreza (extrema, no extrema, no pobre) y re-estima el RDD.
5	Balance de covariables	Estima el RDD con cada covariable como outcome dentro del BW óptimo. Ninguna debería ser significativa.
6	Orden del polinomio	Compara estimaciones con polinomio local de grado 1 (lineal) y grado 2 (cuadrático).
7	Placebo de umbral	Aplica el estimador en percentiles 25 y 75 de la distribución de x. No debe haber efectos.
8	Inferencia por permutación	500 corridas con umbrales aleatorios para obtener una distribución nula del estadístico t.
9	Corrección FDR (BH)	Ajusta los p-valores de pruebas múltiples usando el método Benjamini-Hochberg.

10. Fase 5 — Generación de tablas y figuras

La función `phase_5_output()` lee los CSV intermedios y produce todos los outputs del paper:

Tablas LaTeX

- **Table 1 (summary):** estadísticas descriptivas (media, SD, N) de outcomes y covariables separadas por tratados vs. control, incluyendo nota con tamaños de muestra dentro del BW.
- **Table 2 (main results):** estimaciones RDD por especificación y outcome, con SE, IC 95% y panel de heterogeneidad por SISFOH.
- **Table 3 (robustness):** paneles de sensibilidad al BW, donut-hole, polinomios y placebos.
- **Table 4 (covariate balance):** estimaciones RDD con covariables como outcome; asterisco (*) si el IC excluye cero.

Todas las tablas usan el entorno `threeparttable` y pasan por una función de validación que reemplaza `nan/NaN/None` y celdas vacías por `'---`' automáticamente.

Figuras

- **Figure McCrary:** histograma de densidad de la running variable a ambos lados del umbral.

- **Figure 1 (RD plot):** dispersión binada + regresión local a cada lado del corte, restringida a $\pm h \times 2.5$ años alrededor de los 65.
- **Figure 2 (BW sensitivity):** gráfico de puntos con IC para las tres especificaciones de ancho de banda.

Todas las figuras se guardan en PNG (150 dpi) y PDF (300 dpi) para uso directo en LaTeX.

11. Variables clave del análisis

Variable	Tipo	Descripción
EDAD (running var)	Continua	Edad del individuo; centrada en 65 $\rightarrow$ running_centered
TIENE_BILLETERA	Binaria	1 = posee billetera digital (ENAH0 P558E1_9)
USA_BILLETERA	Binaria	1 = usó billetera en alguna transacción (P558H*_7)
treat	Binaria	1 si running_centered ≥ 0 (i.e., edad ≥ 65)
INTERNET_HOGAR	Binaria	Acceso a internet en el hogar (covariate / placebo)
SMARTPHONE	Binaria	Hogar tiene smartphone (covariate / placebo)
POBREZA	Categorica	Condición de pobreza SISFOH (1=extrema, 2=no extrema, 3=no pobre)
INGRESO_PC	Continua	Ingreso per cápita del hogar (sumaria)
NIVEL_EDUCATIVO	Ordinal	Máximo nivel educativo alcanzado
DPTO	Cluster	Código de departamento — usado para SE clusterizados
FACTOR_EXPANSION	Peso	Factor de expansión poblacional ENAH0 (FACPOB07)

12. Archivos de salida

Archivo	Descripción
data/clean/enaho_2024_clean.csv	Dataset ENAH0 2024 fusionado a nivel de persona
data/clean/clean_data.csv	Muestra RDD filtrada con running variable centrada
data/clean/main_results.csv	Estimaciones RDD principales (todas las especificaciones)
data/clean/robustness_results.csv	Resultados de todas las pruebas de robustez
paper/tables/table_1_summary.tex	Estadísticas descriptivas tratados vs. control
paper/tables/table_2_main_results.tex	Tabla principal de resultados RDD
paper/tables/table_3_robustness.tex	Sensibilidad de ancho de banda, donut, polinomios, placebos
paper/tables/table_4_covariate_balance.tex	Balance de covariables en el ancho de banda
paper/figures/figure_mccrary_density.{png,pdf}	Densidad de la variable de corrida (test de McCrary)

Archivo	Descripción
paper/figures/figure_1_rdpplot.{png,pdf}	Gráfico RDD principal (billetera vs. edad centrada)
paper/figures/figure_2_bandwidth_sensitivity Sensitivity	Sensibilidad de estimados al ancho de banda

13. Cómo ejecutar el pipeline

Requisitos previos:

- Python 3.9 o superior.
- Conexión a internet (descarga ~38 MB de ZIPs → ~511 MB de CSVs en disco).
- Los paquetes se instalan automáticamente si faltan.

Comando de ejecución desde la raíz del repositorio:

```
python scripts/script_completo/script.py
```

El pipeline completo puede tardar **entre 10 y 40 minutos** dependiendo de la velocidad de internet y el hardware. Al finalizar imprime la ruta de todos los outputs generados.

14. Notas de diseño y decisiones técnicas

- **Portabilidad:** todas las rutas son relativas a `__file__`; no hay rutas absolutas hard-coded.
- **Fallback automático:** si `rdrobust` no está disponible o falla, el script continúa con WLS statsmodels sin interrumpir el pipeline.
- **Reproducibilidad:** `np.random.seed(42)` y `np.random.default_rng(42)` en todas las rutinas estocásticas.
- **Detección robusta de columnas:** cada fase verifica si las columnas existen antes de operar sobre ellas, evitando errores si la estructura de ENAHO cambia.
- **Validación de tablas:** la función `_validate_table()` sanea automáticamente cualquier valor NaN o celda vacía antes de escribir el `.tex`.
- **Figuras no-interactivas:** se usa `matplotlib.use('Agg')` para evitar que se abra una ventana gráfica en entornos sin display.